RNA-seq 转录组分析报告

Standardized Transcriptome Sequencing Analysis & Data Lineage Report

6 Samples 2 Groups

STUDY INFORMATION
研究信息

委托单位
本地测试课题组

研究物种
Mus musculus

参考基因组
GRCm39

核心比较组
Group 2 vs Group 1

ANALYSIS PROVENANCE
分析溯源

项目编号
PRJ-RNA-PDF-001

RNAFlow 流程版本
RNAFlow example

BioReport 报告引擎版本
BioReport v2.0.0

数据完整性校验状态
已记录 SHA-256 指纹（8 个输入文件），未与外部基准比对

报告生成日期 2026-10-17

目录

1 摘要 3
1.1 差异表达客观统计汇总 3
1.2 结果概览（客观汇总，非机制推断） 3
1.3 数据范围与溯源说明 3
2 项目概况 4
2.1 样本信息 4
3 分析方法与软件版本 5
3.1 分析流程工作流 5
3.2 实际提供的软件版本 5
4 质量控制 6
4.1 fastp 测序质控 6
4.2 外源污染检测 9
4.3 QualiMap 比对质控 11
4.4 STAR 比对统计 11
5 分析结果 12
5.1 样本关系与表达分布 12
5.2 表达矩阵预览 13
5.3 高变异基因表达模式 14
5.4 差异表达分析 15
5.5 功能富集分析 16
6 详细分析方法（附录） 19
6.1 质量控制与比对统计方法 19
6.2 表达定量与下游结果分析方法 19
7 溯源信息 20
8 交付文件与报告说明 21
8.1 报告生成架构 22
8.2 交付数据目录索引与映射说明 22
8.3 开发者与项目信息 24
参考文献 24

1 摘要

本章节汇总了当前转录组（RNA-seq）分析流程的核心质控与定量统计指标。本项目共纳入 **6** 个测序样本（划分为 **2** 个实验分组）。测序数据经质控后平均 Q30 达 **95.86%**，平均参考基因组比对率为 **99.04%**，全样本共检出有效表达基因 **16289** 个。在差异表达分析中，核心比较组（**2_vs_1**）在原始 P < 0.05 且 |log2FC| > 1 的展示口径下，共 **7069** 个差异表达基因（上调 4364、下调 2705）。另按 padj < 0.05（不附加 log2FC 阈值）统计，有 **11750** 个基因。原始 P 口径不等价于 FDR 控制。各环节关键指标概览如下：

样本数	分组数	平均 Q30
6	**2**	**95.86%**

平均比对率	检出基因数	2_vs_1 差异基因数
99.04%	**16289**	**7069**

检出基因数为表达矩阵中至少 1 个样本 TPM > 1 的基因并集；PCA 与表达分布图采用全样本平均 TPM > 1 的口径，两口径不同，不构成矛盾。

1.1 差异表达客观统计汇总

以下为输入结果的客观统计汇总；各比较组独立计数，不合并去重，不由此推断生物学机制。

表 1-1　各比较组差异表达基因数量汇总

比较组	上调	下调	满足阈值差异基因	padj<0.05 基因数	参与检验的基因总数
2_vs_1	4364	2705	7069	11750	33824

1.2 结果概览（客观汇总，非机制推断）

- 样本与质控：6 个样本 / 2 组；平均 Q30 95.86%，平均比对率 99.04%。
- 差异表达：2_vs_1 在原始 P<0.05、|log2FC|>1 口径下共 7069 个（上调 4364、下调 2705）；另有 11750 个基因满足 padj<0.05（不附加 log2FC 阈值）。
- 上调基因富集线索：rRNA processing、ribosome biogenesis、methylation（最小 p.adjust 9.16e-22）。
- 下调基因富集线索：extracellular matrix、angiogenesis、basement membrane（最小 p.adjust 1.22e-64）。
- 以上为上游结果文件中的客观统计与条目名称，不据此推断生物学机制；样本一致性和测序深度提示见对应章节。

1.3 数据范围与溯源说明

本报告直接读取上游分析产物以生成所选模块的统计汇总与可视化图表，不重新执行序列比对或差异统计检验。完整的原始数据、文件路径及 SHA256 校验值请参阅「溯源及交付」章节；各项统计指标的计算分母与筛选阈值详见「项目概况」及后续对应结果章节。

2 项目概况

本报告由 CygnusX BioOps 生态 **BioReport** 自动化报告引擎生成，系统性汇总并解析了 RNAFlow 转录组上游分析流程的产出结果。报告涵盖原始数据质控、外源污染筛查、参考基因组（GRCm39）比对评估、样本间表达谱聚类、差异表达基因（DEG）筛选及功能富集分析等核心模块，旨在为下游实验验证与生物学机制探索提供规范化的数据概览与全流程可复现记录。

核心指标说明

- **样本数与分组数**：依据实验设计元数据表（Sample Sheet）解析的有效样本总量及对比组设置。
- **平均 Q30**：全样本过滤后 Clean Reads 中 Phred 质量得分 ≥ 30（碱基识别准确率 $\geq 99.9\%$）的比例算术均值，用于评估测序底层碱基质量。
- **平均比对率**：全样本成功映射至参考基因组（GRCm39）的 Reads 占总有效 Clean Reads 比例的算术均值，反映文库序列与参考基因组的整体匹配效率及测序有效性。
- **检出基因数**：全样本基因表达矩阵中，至少在 1 个样本中表达丰度满足 $\mathrm{TPM} > 1$ 的已注释基因总数，反映本次测序在转录组广度上的有效覆盖能力。

各比较组统计摘要见摘要章节；原始 P 值与 log2FC 的展示判定口径不等价于 FDR 控制。报告不依据汇总指标自动判定质控通过与否，也不自动推断生物学机制。

2.1 样本信息

下表展示纳入本次分析的样本元数据映射关系。其中 `sample` 为上游原始分析流程中的内部样本标识，`sample_name` 为报告图表中统一展示的规范化样本名称，`group` 为实验设计分组标识。后续章节的图表与表达矩阵均按分组（`group`）及组内输入顺序排列展示。

表 2-1 样本与实验分组信息

sample	sample_name	group
1-1_raw	1-1	1
1-2_raw	1-2	1
1-3_raw	1-3	1
2-1_raw	2-1	2
2-2_raw	2-2	2
2-3_raw	2-3	2

样本预览 6 / 6 行，最多 6 列；按分组与组内输入顺序排列。sample 与 sample_name 保留原始对应关系。完整样本信息（数据目录内相对路径）：index/sample.csv

3 分析方法与软件版本

本报告系统采用“计算与渲染解耦”架构，直接读取上游标准生信分析流水线已产出的统计矩阵与结果文件进行标准化重绘与排版，报告生成过程本身不重新执行序列比对、差异表达检验或功能富集计算。以下方法学说明仅对应当前配置所启用的报告模块，软件具体版本号以流程运行记录为准。

3.1 分析流程工作流

本项目基于 RNAFlow (版本: RNAFlow example) 标化分析流水线执行，核心分析节点及依赖的关键工具链如下所示：

1. Raw Reads	**2. fastp**	**3. FastQ Screen**	**4. STAR**
5. RSEM	**6. DESeq2**	**7. clusterProfiler**	

以上为常见分析路径；仅当前启用模块的方法与输入软件版本记录纳入下文，不据流程示意断言全部步骤已执行。

3.2 实际提供的软件版本

表 3-1 分析软件与版本信息

Software	Version	Function
MultiQC	v1.31	质控报告整合
Fastq Screen	v0.16.0	物种污染筛查
Fastp	v1.0.1	数据过滤与接头切除
Qualimap	v2.3	比对结果质量评估
RSEM	v1.3.3	基因表达定量
DESeq2	v1.46.0	差异表达分析
clusterProfiler	v4.14.0	GO/KEGG 富集分析

软件版本来源（数据目录内相对路径）：software_versions.yaml。正文仅列与当前模块对应的输入版本记录；完整原始版本表保留在该文件中，不据此断言可选分析已执行。

4 质量控制

表 4-1 常见 QC 参考范围对照

指标	常见参考范围	本次值	是否在常见范围
平均 Q30	≥ 85%	95.86%	是
平均比对率	≥ 80%	99.04%	是
重复率 Dup	< 20%（视文库类型）	11.7–23.9%	部分偏高
GC 含量	与物种预期一致	49.1–50.6%	需结合物种判断
过滤保留率 Retained	≥ 90%	95.5–96.6%	是
Unique 比对率	≥ 80%	91.3–93.0%	是
测序深度均衡 max/min	< 1.5	2.1	否

表中参考范围为常见经验值，不是强制判定标准；是否在常见范围仅作客观对照，最终质控判定由研究人员负责。GC 含量需结合物种与文库类型判断。

4.1 fastp 测序质控

高通量测序原始数据（Raw Reads）通常包含少量接头序列残留（Adapter）、末端低质量碱基及未知碱基（N），直接用于比对分析易引入假阳性错配。本节采用 `fastp` 对原始序列进行质控与接头切除，核心统计指标见下表。后文分别通过条形图展示过滤序列的构成分布，以及双端序列（Read 1 / Read 2）各测序周期的碱基质量演变曲线。

核心指标说明：

- **Dup (%)**：重复序列占比（Duplication rate），反映文库复杂度。
- **Q30 (%)**：过滤后 Phred 质量得分 ≥ 30（准确率 $\geq 99.9\%$）的碱基占比，衡量碱基识别可靠度。
- **GC (%)**：过滤后有效序列中 G/C 碱基占比，用于监控 GC 偏好性。
- **Retained (%)**：质控后保留的 Clean Reads 占原始 Reads 的比例（过滤保留率）。
- **Adapter (%)**：检出并完成修整的接头污染序列比例。

表 4-2 fastp 测序质量统计

Sample	Dup (%)	Q30 (%)	GC (%)	Retained (%)	Adapter (%)
1-1	13.57	96.87	49.31	96.62	2.63
1-2	12.79	95.86	49.13	96.08	2.59
1-3	11.74	96.54	49.49	96.40	2.36
2-1	23.13	94.67	49.71	95.46	3.19
2-2	23.90	95.87	49.13	95.93	3.88
2-3	16.16	95.36	50.62	95.91	2.89

fastp 统计预览 6 / 6 行；单位为百分比，缺失值显示 NA。完整结果（数据目录内相对路径）：fastp_trim_report/multiqc_general_stats.txt **图表口径**：过滤分类图保留各类 Reads 计数；碱基质量曲线分别展示 R1/R2 的逐位置平均 Phred 得分。关键图模式使用过滤后（After filtering）阶段，完整模式保留全部阶段；图例与数据源见图注。

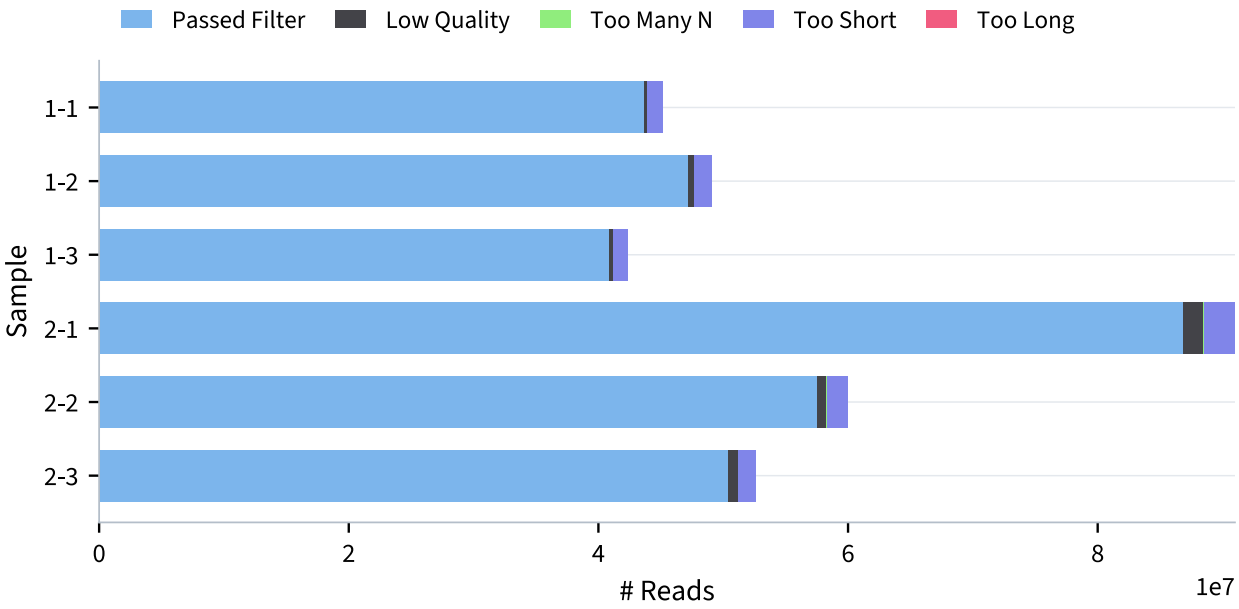


图4-1 Fastp: Filtered Reads。横轴：# Reads；纵轴：Sample。颜色与图例对应输入样本或统计类别。

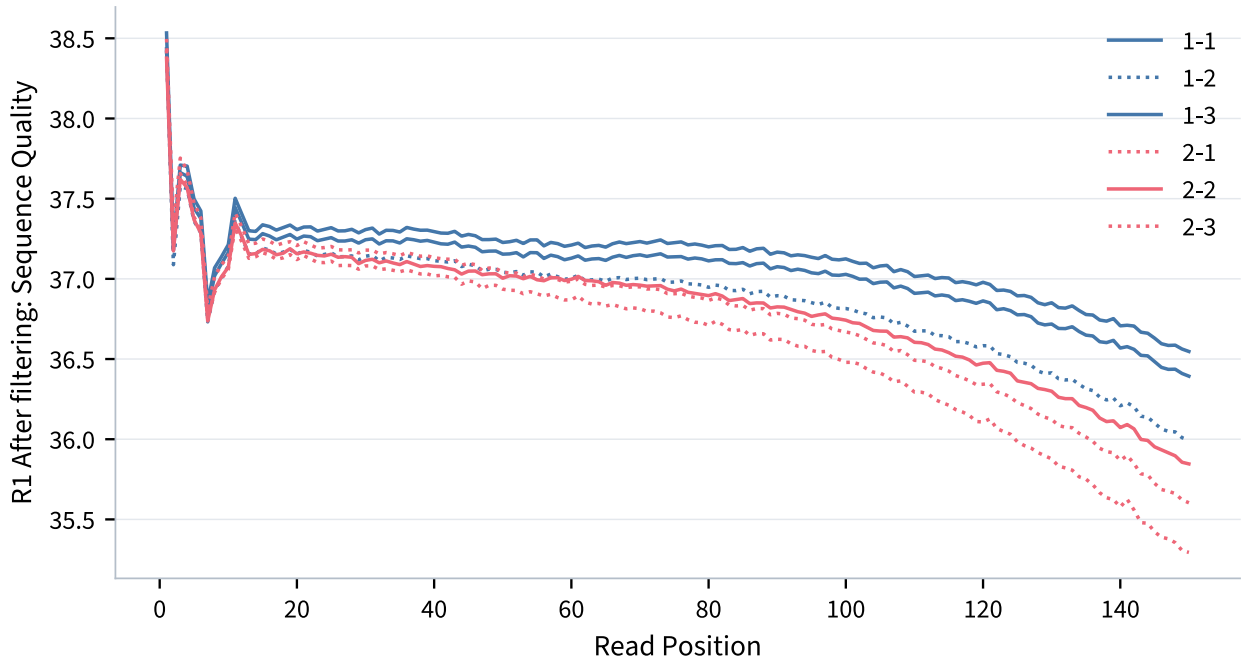


图4-2 Fastp: Sequence Quality：Read 1: After filtering。横轴：Read Position；纵轴：R1 After filtering: Sequence Quality。颜色与图例对应输入样本或统计类别。

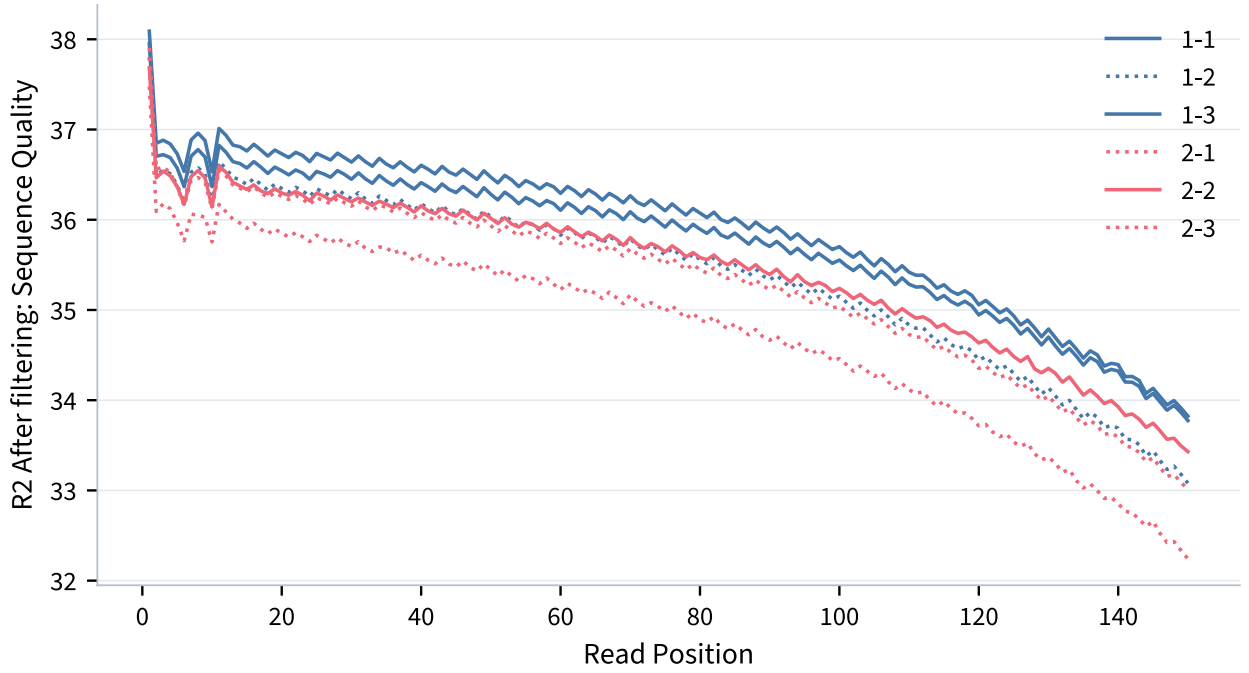


图4-3 Fastp: Sequence Quality：Read 2: After filtering。横轴：Read Position；纵轴：R2 After filtering: Sequence Quality。颜色与图例对应输入样本或统计类别。

质控图读取 MultiQC 保存的 fastp 汇总数据集；正文保留关键图，过滤曲线使用 After filtering 阶段。完整质控结果（数据目录内相对路径）：fastp_trim_report/multiqc_short_read_trim_report_data

4.2 外源污染检测

为排查实验取样、RNA 提取或文库构建过程中潜在的跨物种交叉污染、载体残留及环境微生物混入，本模块基于 FastQ Screen 随机抽取测序序列与多物种参考基因组数据库进行比对，分别展示双端测序 Read 1 与 Read 2 的物种比对分布情况。

读图指南：默认横轴为抽样比对的 Reads 数量（可在 analysis.fastq_screen.axis 切换为按样本归一化的百分比，默认抽样 100,000 条），纵轴为样本名称。在无明显外源污染的样本中，目标研究物种的单基因组特异比对（图例所示颜色）与多基因组共比对（Multiple Genomes，主要源于真核生物间高度保守的同源基因或残留核糖体 rRNA 序列）应占据绝对主导地位；其余非目标物种（如人源、细菌、真菌或植物基因组）的特异比对色块占比可用于客观评估外源核酸混入水平。若汇总样本未覆盖样本表，图注会明确报告实际汇总数与缺失样本。

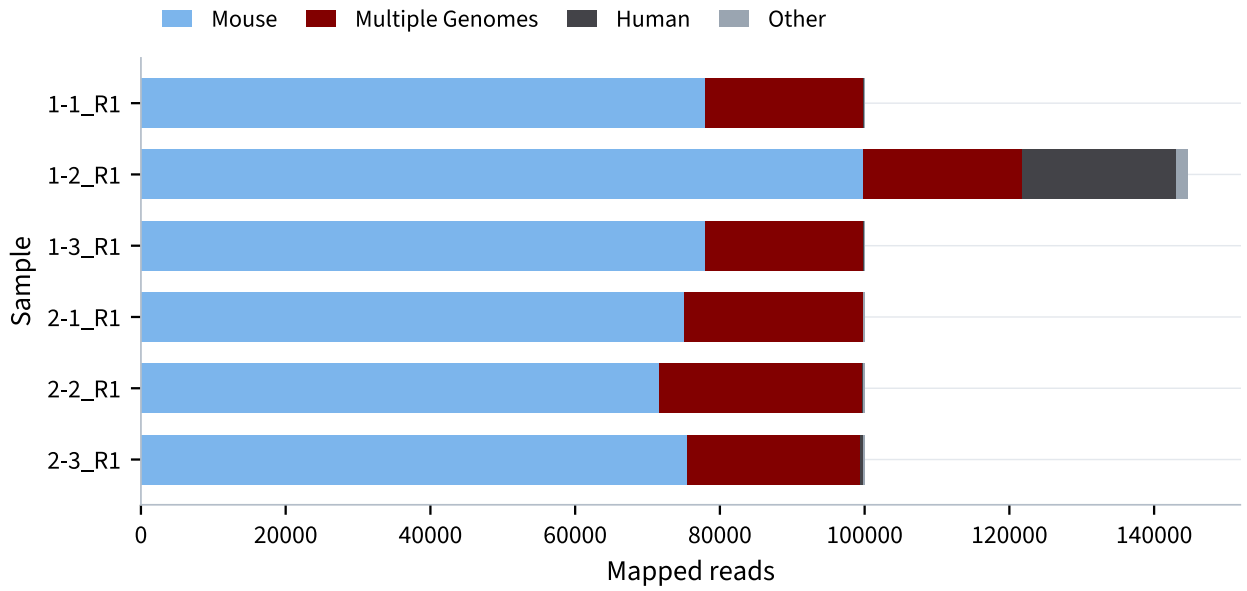


图4-4 FastQ Screen: Mapped Reads。横轴：Mapped reads；纵轴：Sample。颜色与图例对应输入样本或统计类别。Other 为仅显示层聚合，原始类别完整保留在输入数据中。

外源污染评估图读取 MultiQC 保存的 FastQ Screen 汇总数据集。完整质控结果（数据目录内相对路径）：fastq_screen_report/fastq_screen_multiqc_r1/multiqc_r1_fastq_screen_report_data

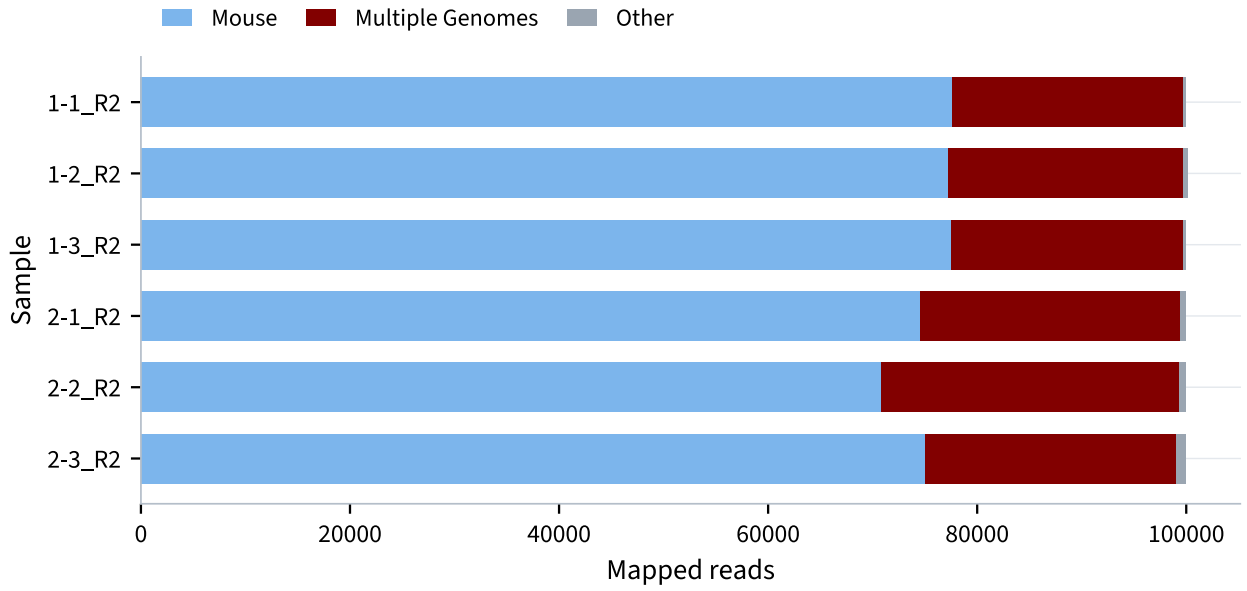


图4-5 FastQ Screen: Mapped Reads。横轴：Mapped reads；纵轴：Sample。颜色与图例对应输入样本或统计类别。Other 为仅显示层聚合，原始类别完整保留在输入数据中。

外源污染评估图读取 MultiQC 保存的 FastQ Screen 汇总数据集。完整质控结果（数据目录内相对路径）：fastq_screen_report/fastq_screen_multiqc_r2/multiqc_r2_fastq_screen_report_data

4.3 QualiMap 比对质控

比对后质量控制（BamQC）通过 QualiMap 评估测序 Reads 在参考基因组上的比对覆盖深度分布特征。

横轴为基因组覆盖深度（Coverage X），纵轴为基因组窗口计数（Genome bin counts）。该汇总统计包含无覆盖区域；由于 0X 无覆盖 bin 的窗口计数可达 10^9 量级，绘图默认剔除 0X bin（并可切换纵轴对数刻度），以便观察 1X–100X 区间的有效覆盖曲线形态。Genome fraction 曲线同样默认不显示 0X 点。不能仅凭 0X 峰值判定样本质控状态，需结合下方比对统计与实验设计。

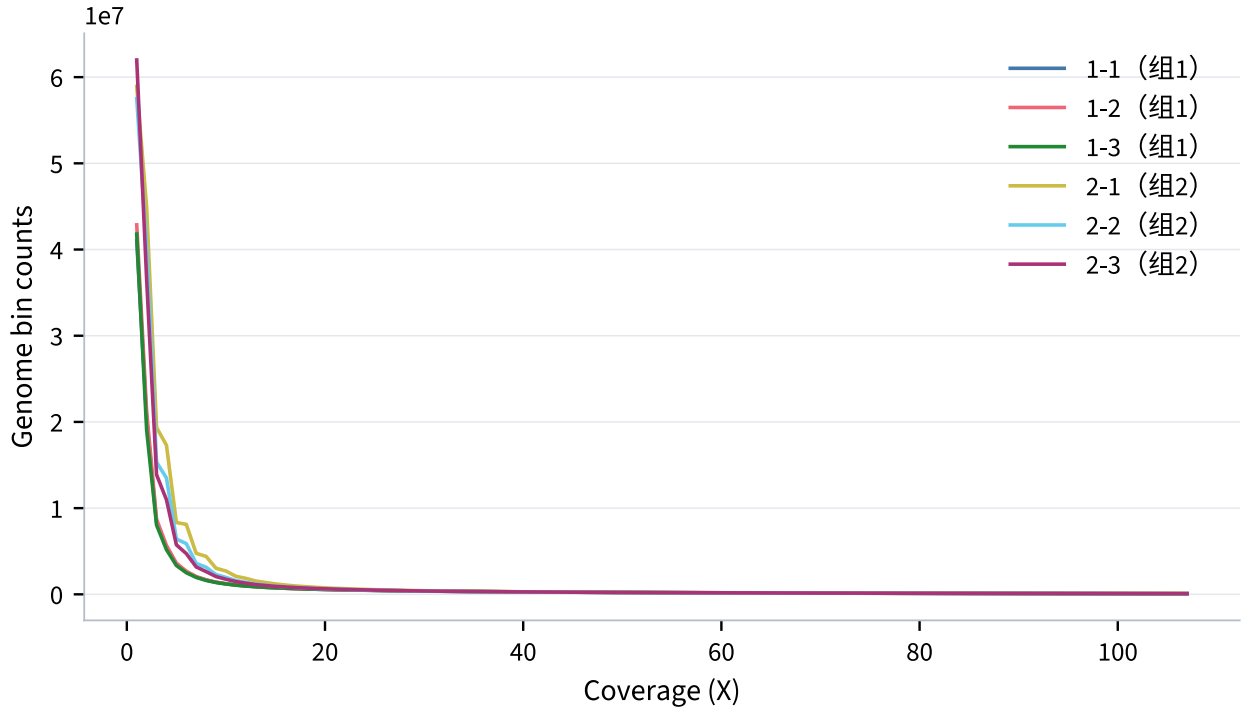


图4-6　QualiMap: BamQC: Coverage histogram。已剔除 0X 无覆盖 bin；横轴：Coverage (X)；纵轴：Genome bin counts。颜色与图例对应输入样本或统计类别。

比对质控图读取 MultiQC 保存的 QualiMap BamQC 汇总数据集。完整质控结果（数据目录内相对路径）：QualiMap/multiqc_data

4.4 STAR 比对统计

下表保留 MultiQC 中最终样本的比对指标，排除 STARpass1。Mapped 表示总比对，Unique 表示唯一位置比对，Multi 表示多位置比对；百分比沿用输入口径，Reads 数值单位见表注。

表 4-3　STAR 比对质量统计

Sample	Total reads	Mapped reads	Mapped (%)	Unique reads	Unique (%)	Multi reads
1-1	21.83	21.72	99.46	19.96	91.43	1.75
1-2	23.58	23.41	99.30	21.54	91.35	1.87
1-3	20.44	20.33	99.48	18.78	91.89	1.55
2-1	43.43	42.95	98.89	40.39	93.01	2.56
2-2	28.77	28.40	98.70	26.58	92.37	1.82
2-3	25.22	24.83	98.42	23.39	92.75	1.43

STAR 显示最终样本（6/6），排除 STARpass1；Reads 单位 Million；来源 index/multiqc_mapping_general_stats.txt。 深度不均衡：2-1 43.43M / 1-3 20.44M = 2.1 倍（参考线 1.5）；建议核查上样量与下机量。

5 分析结果

5.1 样本关系与表达分布

在开展差异表达检验前，需从全局层面考察各样本基因表达谱的整体分布均衡性以及生物学重复样本间的聚类一致性：

- **主成分分析**：通过对高维基因表达矩阵（保留全样本平均 $\mathrm{TPM} > 1$ 的有效表达基因并经 $\log_2(\mathrm{TPM}+1)$ 转换）进行线性降维，将各样本投射至方差解释率最高的前三个主成分平面（左图：PC1 vs PC2；右图：PC2 vs PC3）。坐标轴百分比代表对应主成分对全局表达变异的解释度。图中每个散点代表一个样本，同组生物学重复（相同颜色）在空间上聚集越紧密，表明组内重复性越好；不同处理组间距离越远，表明实验处理引起的转录谱整体差异越显著。若个别样本明显偏离同组其他重复，提示可能存在批次效应、样本混淆或文库质量问题，需进一步核查。
- **样本表达量分布图**：结合小提琴图（外部核密度轮廓）与箱线图（内部中位数横线及四分位距框）展示各样本过滤后表达基因的 $\log_2(\mathrm{TPM}+1)$ 丰度分布形态。各样本的小提琴轮廓宽窄一致且箱线图中位数处于同一水平高度，表明样本间测序深度标准化效果良好，无明显的系统性测量偏倚。
- 图中保留基因数采用全样本平均 TPM > 1 的口径，与摘要中“至少 1 个样本 TPM > 1”的检出基因并集口径不同；两者用于不同图表，不构成矛盾。

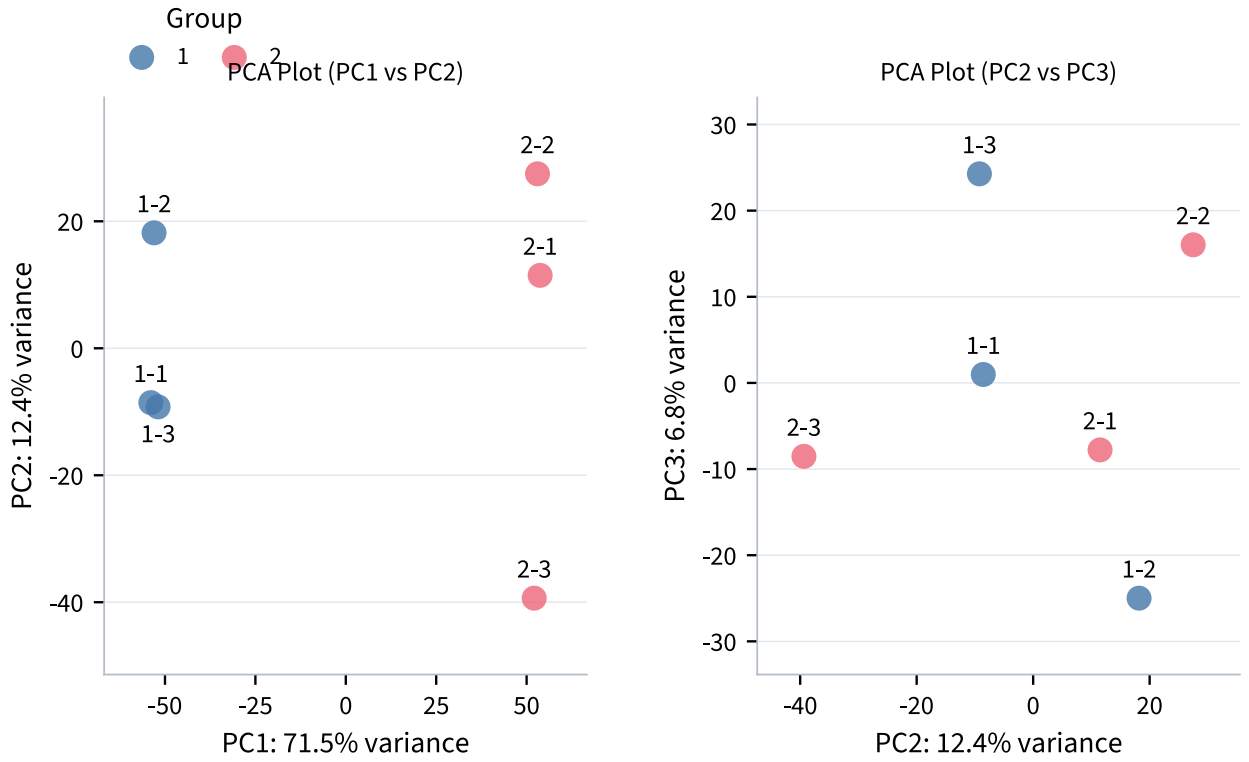


图5-1　样本 PCA：保留平均 TPM > 1 的基因，输入 TPM 经 Log2(TPM + 1) 变换；颜色表示样本分组，坐标轴标注各主成分解释的方差比例。标签位置仅为展示层避让，不改变 PCA 坐标。

PCA 包含 6 个实际匹配样本，每个子图的一点对应一个样本。完整表达矩阵（数据目录内相对路径）：index/merge_rsem_tpm.tsv

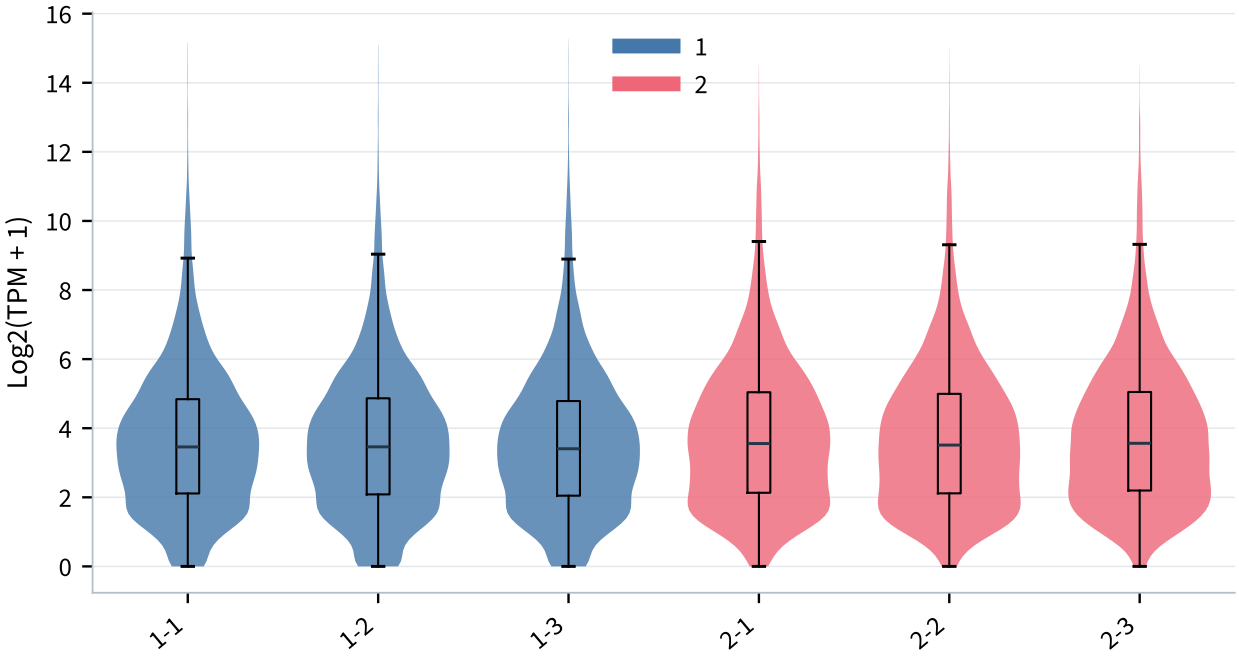


图5-2　样本表达分布：保留平均 TPM > 1 的基因，纵轴为 Log2(TPM + 1)，颜色表示样本分组。

表达分布包含 6 个样本、13614 个过滤后基因；样本按分组与组内输入顺序排列。完整表达矩阵（数据目录内相对路径）：index/merge_rsem_tpm.tsv

5.2 表达矩阵预览

上游流程通过 RSEM 构建全基因组基因水平的表达丰度矩阵，并采用 **TPM（Transcripts Per Million）** 作为标准化定量指标。TPM 在计算时先后对基因外显子有效长度和样本测序总读段数进行了归一化处理，使得每个样本所有基因的 TPM 总和恒等于 10^6，从而支持不同样本间同一基因表达量的直接对比。下表按配置行数、沿输入顺序预览表达矩阵记录（完整表达矩阵包含全部注释基因，详见交付数据文件）。

表 5-1　基因表达量矩阵（TPM）预览

Gene ID	1-1	1-2	1-3	2-1	2-2	2-3	Symbol
ENSMUSG00000000001	21.54	23.70	21.70	29.34	31.22	27.74	Gnai3
ENSMUSG00000000003	0.00	0.00	0.00	0.00	0.00	0.00	Pbsn
ENSMUSG00000000028	4.12	3.69	4.01	2.32	2.07	2.72	Cdc45
ENSMUSG00000000031	224.60	250.01	213.00	90.44	94.53	81.15	H19
ENSMUSG00000000037	0.26	0.46	0.12	0.30	0.36	0.59	Scml2
ENSMUSG00000000049	4.85	0.19	6.06	0.23	2.89	7.79	Apoh
ENSMUSG00000000056	29.07	36.48	28.75	19.54	20.18	19.75	Narf
ENSMUSG00000000058	5.33	5.51	4.95	3.11	2.42	3.01	NA

预览 8 / 78275 行；排序：输入顺序。完整结果（数据目录内相对路径）：index/merge_rsem_tpm.tsv 正文展示 6 / 6 个样本列。

5.3 高变异基因表达模式

高变异基因（Highly Variable Genes, HVGs）是指在跨样本间表达丰度波动最为剧烈的基因集合，通常富集了响应实验处理或决定样本表型分化的核心转录调控特征。本模块在满足全样本平均 $\mathrm{TPM} > 1$ 且方差非零的基因中，按 $\log_2(\mathrm{TPM}+1)$ 的跨样本方差降序选取高变异基因。主报告默认展示 Top 50，完整配置数量的热图作为 supplementary SVG 交付；两者均按基因行进行 Z-score 标准化。实际基因数与聚类参数见图注。

读图指南：热图每一行代表一个基因，每一列代表一个样本（列顺序按 Euclidean 距离与 Ward 聚类算法自动重排，顶部色条标识样本原始分组）。右侧色标 Z-score 反映基因在特定样本中的相对表达高低：暖色调（红色，Z-score > 0）表示该基因在对应样本中的表达量高于全样本平均水平，冷色调（蓝色，Z-score < 0）表示低于平均水平。列聚类仅依据表达相似性对样本进行重排，不预设生物学重复必然相邻。读图时请对照顶部分组色条，观察同组样本是否相邻及是否存在红蓝对角模块；若个别样本未与同组样本相邻，应结合 PCA 与质控信息进一步核查，不直接据此判定分组效应。

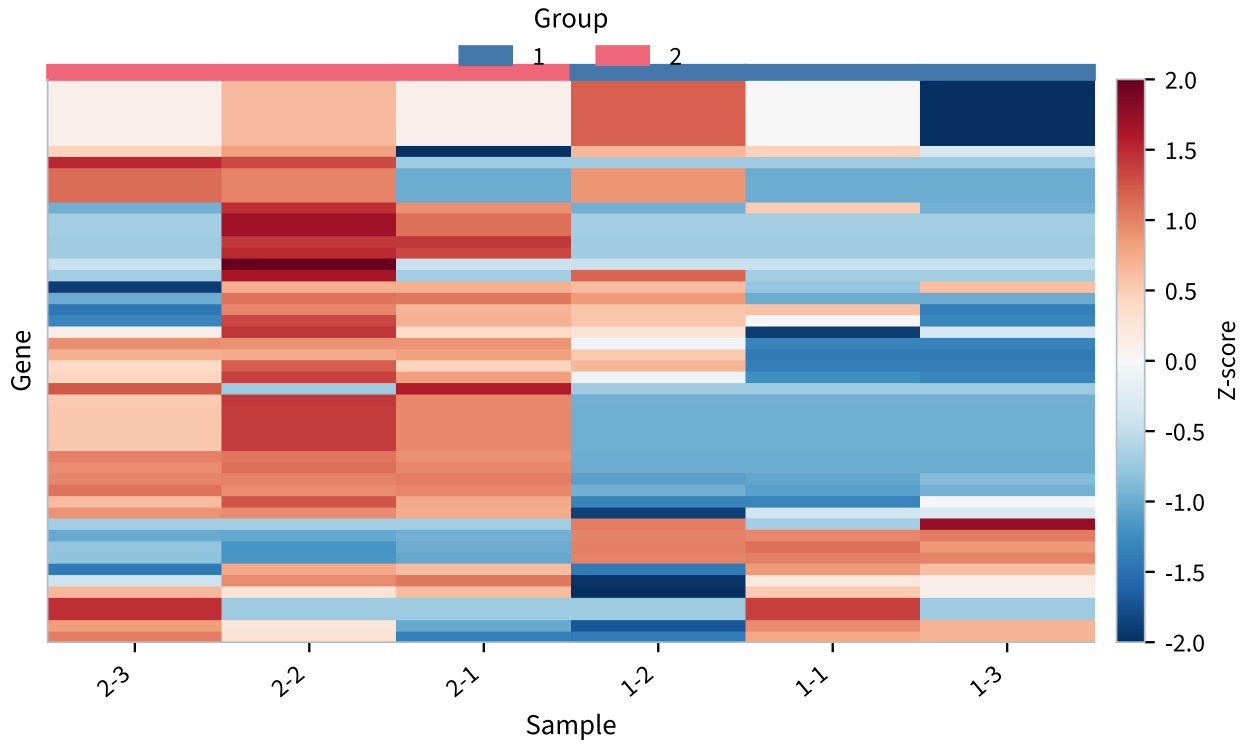


图5-3　高变异基因热图：50 个基因。筛选平均 TPM > 1 和非零方差基因，对 Log2(TPM+1) 的方差排序选取；按基因行进行 Z-score。分组注释条位于图上方；色标范围 -2 到 2，超出范围按端点颜色显示。行距离 correlation（已聚类），列距离 Euclidean（已聚类），使用原有 Ward linkage。基因数 > 40 时静态图隐藏行名。

主图展示 50 个基因；完整热图：supplementary/hvg-top-1000.svg（1000 个基因）。样本顺序沿用实际聚类结果。完整表达矩阵（数据目录内相对路径）：index/merge_rsem_tpm.tsv

5.4 差异表达分析

读取上游 DESeq2 结果，方向为 Treat 相对 Control。图中横轴为 log2FoldChange，纵轴为原始 P 值的负对数；红色表示上调，蓝色表示下调，灰色表示未同时满足当前展示阈值。虚线标出阈值；顶部“上限+”表示仅在绘图层裁剪。此处原始 P 值判定不等价于多重检验后的 FDR 控制，原始 pvalue/padj 和上游结果保持不变。

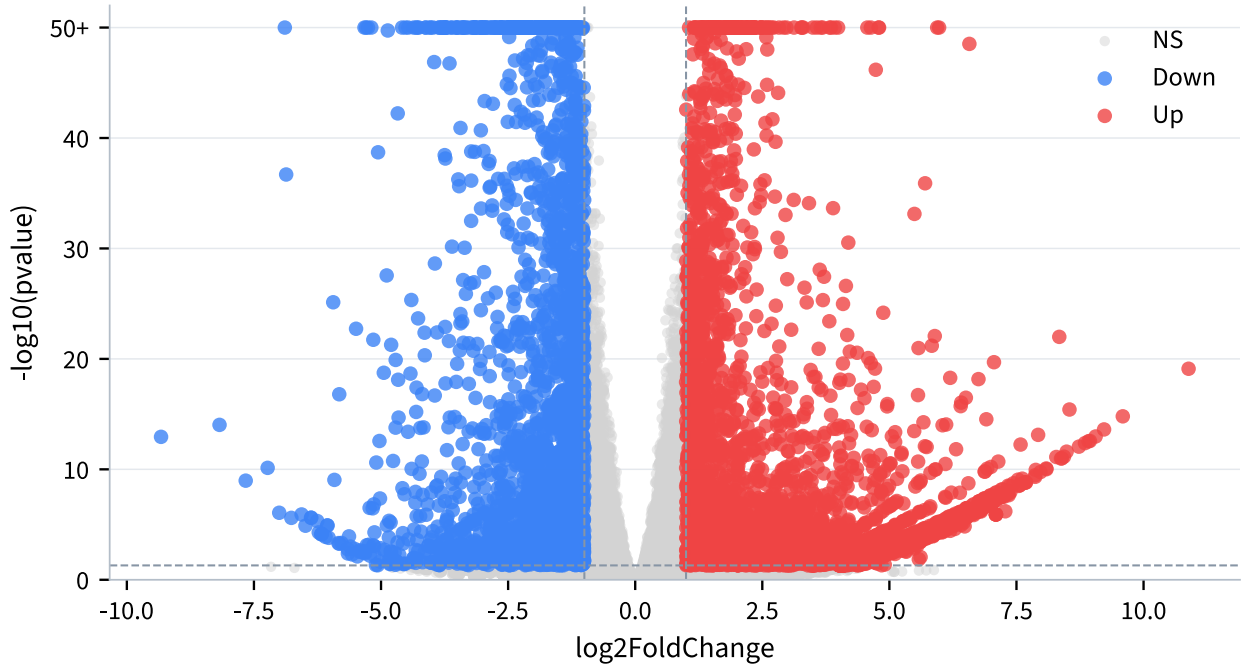


图5-4　2_vs_1 差异表达火山图。方向为 Treat 相对 Control；右侧上调、左侧下调；原始 P < 0.05 且 |Log2FC| > 1.0。上调 4364、下调 2705。超出展示上限的 -log10(P) 在绘图层裁剪至 50（顶部标注为“50+”），原始 pvalue/padj 与上游结果保持一致。图中为上调/下调各 Top 5 显著基因添加基因名引线标注。

2_vs_1：上调 4364，下调 2705；其余记录未同时满足上述阈值。

5.4.1 2_vs_1 Top 5 Up

表 5-2　2_vs_1 Up 差异表达基因预览

Gene ID	Symbol	log2FoldChange	pvalue	padj
ENSMUSG00000108414	Snhg1	3.85	0 (输入)	0 (输入)
ENSMUSG00000005413	Hmox1	3.27	0 (输入)	0 (输入)
ENSMUSG00000021701	Plk2	3.12	0 (输入)	0 (输入)
ENSMUSG00000085385	NA	3.65	5.46e-225	6.18e-222
ENSMUSG00000074578	NA	3.93	1.74e-205	1.71e-202

预览 5 / 4364 行；排序：pvalue 升序、同值按 |log2FC| 降序。完整结果（数据目录内相对路径）：res/DEG/2_vs_1_DEG.csv

5.4.2 2_vs_1 Top 5 Down

表 5-3　2_vs_1 Down 差异表达基因预览

Gene ID	Symbol	log2FoldChange	pvalue	padj
ENSMUSG00000029661	Col1a2	-4.59	0 (输入)	0 (输入)
ENSMUSG00000026043	Col3a1	-4.46	0 (输入)	0 (输入)
ENSMUSG00000040249	Lrp1	-4.02	0 (输入)	0 (输入)
ENSMUSG00000024529	Lox	-3.97	0 (输入)	0 (输入)
ENSMUSG00000000184	Ccnd2	-2.84	0 (输入)	0 (输入)

预览 5 / 2705 行；排序：pvalue 升序、同值按 |log2FC| 降序。完整结果（数据目录内相对路径）：res/DEG/2_vs_1_DEG.csv

5.5 功能富集分析

在获取差异表达基因列表后，为进一步揭示差异基因显著聚集的生物学过程、细胞组分或分子功能通路，本模块按比较组及表达变化方向（上调基因集与下调基因集分别独立富集）依次展示 clusterProfiler 富集分析结果。气泡图与预览表使用同一阈值、有效条目集合及 Top N 配置，按 p.adjust 稳定升序排列；长标签过多时分图展示，并保持同一方向色标与气泡比例尺。原始完整结果保留在交付数据目录中。

- **Description**：富集命中的功能条目或信号通路标准名称。
- **GeneRatio（横轴）**：分数形式为“命中条目基因数 / 该方向 DEG 中成功注释到该数据库的基因数”。分母是该方向富集的有效注释背景（例如上调 1977、下调 2321），不是该方向全部 DEG 数；未注释到该数据库的 DEG 不进入分母，因此上、下调方向的背景数可以不同。表格以分数形式呈现，图中转换为小数比例；比值越大表示差异基因在该条目中的富集浓度越高。
- **Count（气泡面积）**：直接落入该功能条目的差异表达基因绝对数量，气泡越大代表受影响的基因数目越多。
- **p.adjust（气泡颜色）**：经 Benjamini-Hochberg (BH) 等方法进行多重假设检验校正后的显著性 P 值。色标由冷色（蓝）至暖色（深红）映射显著性梯度，颜色越偏向深红代表 p.adjust 越小、功能富集越显著。

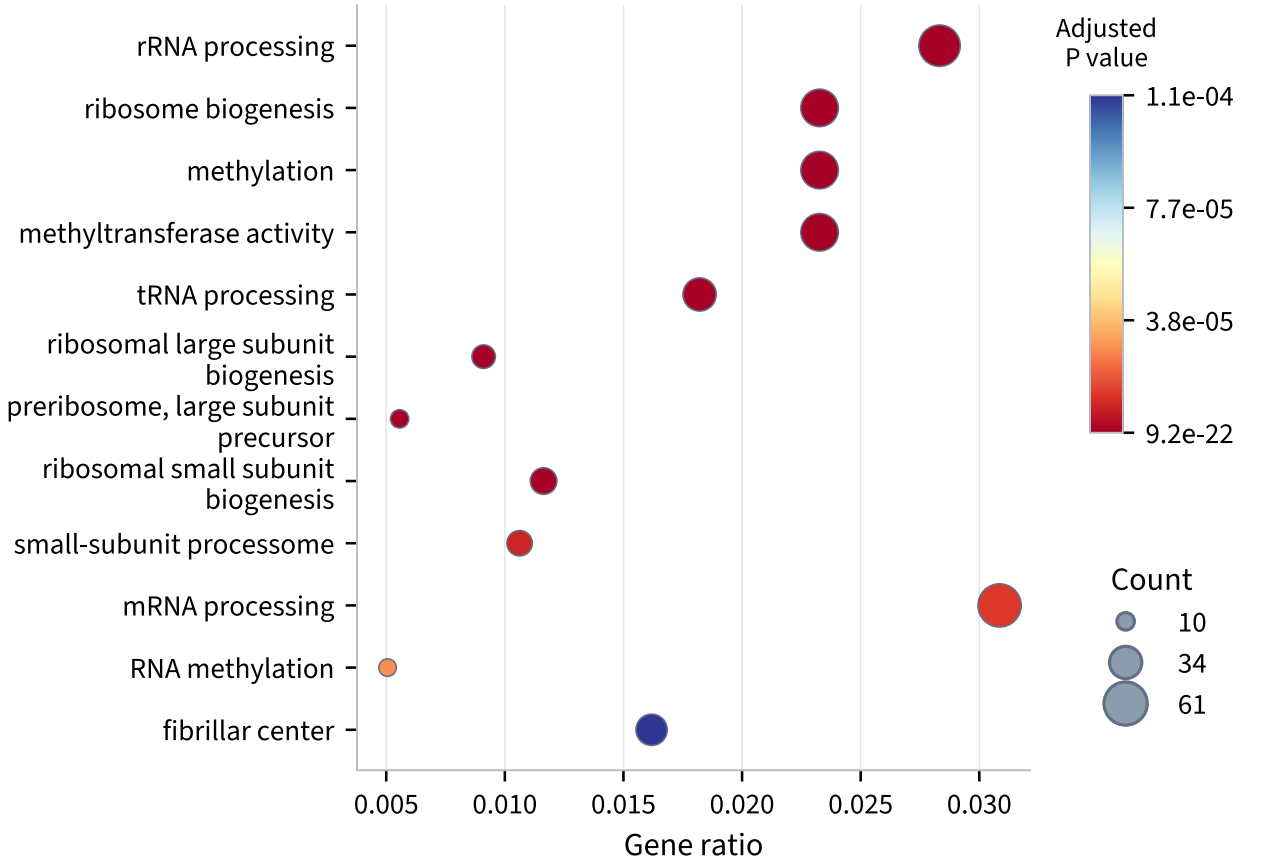


图5-5　2_vs_1 上调富集分析（GO），Top 12 中条目 1–12（实际展示 12）。基因比例为输入 GeneRatio；气泡面积对应 Count，颜色对应校正后 P 值。同一方向各分图共用色标和气泡大小比例。

表 5-4　2_vs_1 上调功能富集结果预览

Description	GeneRatio	Count	p.adjust
rRNA processing	56/1977	56	9.16e-22
ribosome biogenesis	46/1977	46	1.20e-18
methylation	46/1977	46	1.30e-11
methyltransferase activity	46/1977	46	1.30e-11
tRNA processing	36/1977	36	5.14e-11
ribosomal large subunit biogenesis	18/1977	18	1.07e-8
preribosome, large subunit precursor	11/1977	11	1.30e-7
ribosomal small subunit biogenesis	23/1977	23	7.06e-7
small-subunit processome	21/1977	21	8.75e-6
mRNA processing	61/1977	61	1.32e-5
RNA methylation	10/1977	10	2.87e-5
fibrillar center	32/1977	32	1.15e-4

预览 12 / 12 行；排序：p.adjust 升序、同值按 |log2FC| 降序。完整结果（数据目录内相对路径）：res/Enrichments/2_vs_1_UP.csv

2_vs_1 上调：116 / 3788 个条目满足校正后 P < 0.1；正文展示前 12 个。

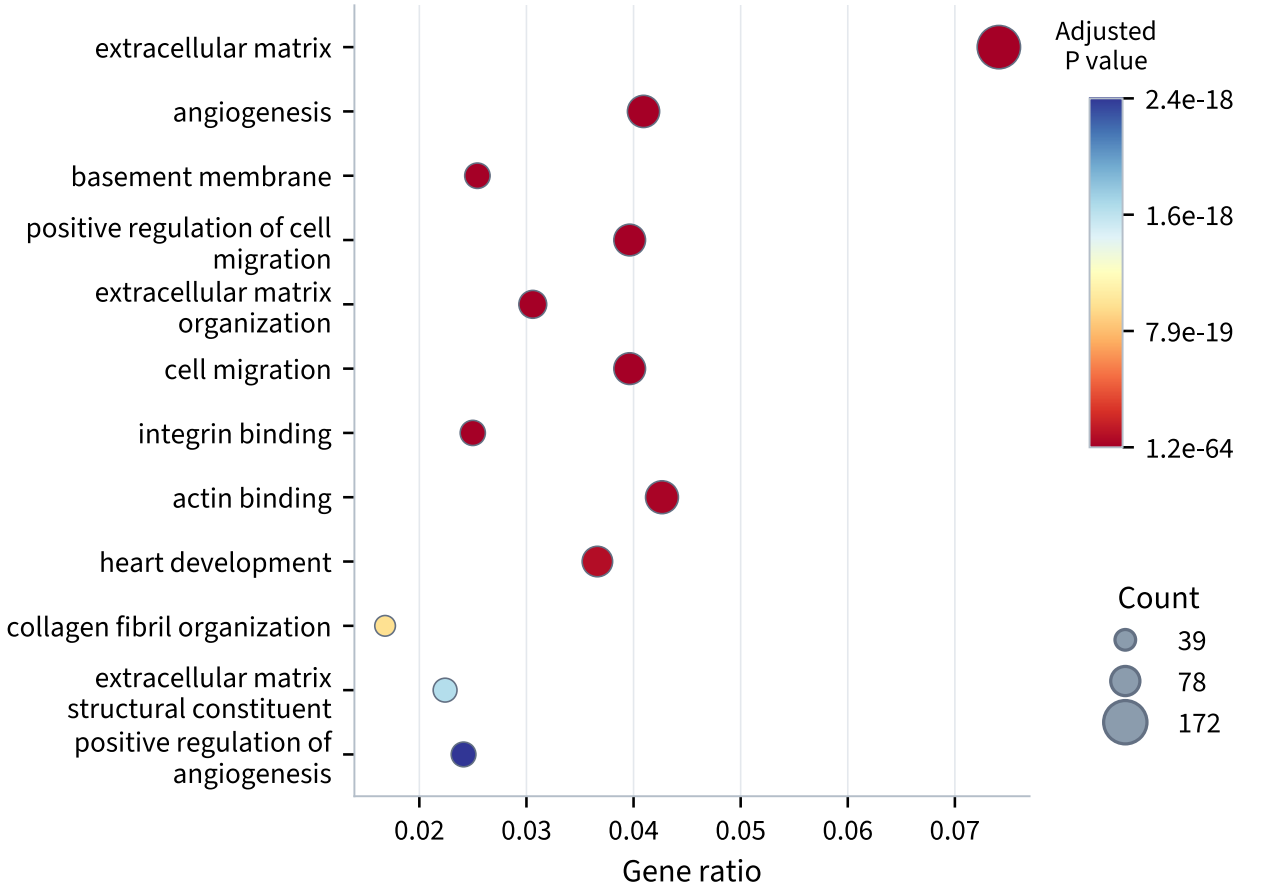


图5-6　2_vs_1 下调富集分析（GO），Top 12 中条目 1–12（实际展示 12）。基因比例为输入 GeneRatio；气泡面积对应 Count，颜色对应校正后 P 值。同一方向各分图共用色标和气泡大小比例。

表 5-5　2_vs_1 下调功能富集结果预览

Description	GeneRatio	Count	p.adjust
extracellular matrix	172/2321	172	1.22e-64
angiogenesis	95/2321	95	2.32e-28
basement membrane	59/2321	59	1.74e-27
positive regulation of cell migration	92/2321	92	3.92e-27
extracellular matrix organization	71/2321	71	5.50e-27
cell migration	92/2321	92	7.22e-24
integrin binding	58/2321	58	8.13e-22
actin binding	99/2321	99	2.53e-20
heart development	85/2321	85	7.08e-20
collagen fibril organization	39/2321	39	9.68e-19
extracellular matrix structural constituent	52/2321	52	1.63e-18
positive regulation of angiogenesis	56/2321	56	2.38e-18

预览 12 / 12 行；排序：p.adjust 升序、同值按 |log2FC| 降序。完整结果（数据目录内相对路径）：res/Enrichments/2_vs_1_DOWN.csv

2_vs_1 下调：1553 / 4323 个条目满足校正后 P < 0.1；正文展示前 12 个。

6 详细分析方法（附录）

6.1 质量控制与比对统计方法

本模块读取上游质控与比对工具的汇总数据进行多维度质量评估，仅所选子模块对应的结果纳入报告。各质控子图的数据源统一解析自 **MultiQC** 生成的标准化汇总数据集[1]：

1. **原始序列过滤与碱基质控**：上游使用 **fastp**[2] 对原始测序读段（Raw Reads）执行自动接头识别与切除、低质量碱基滑窗修剪及过短序列过滤，并统计过滤前后的 Q20/Q30 比例、GC 含量与序列重复率（Duplication rate）。
2. **外源物种污染筛查**：使用 **FastQ Screen**[3] 从各样本随机抽样测序序列，与预构建的多物种参考基因组索引库（涵盖目标物种、常见模式生物、人类、微生物及克隆载体等）进行比对，统计单一物种特异比对与多物种共比对比例。
3. **基因组比对与转录本定量**：采用可变剪接感知型比对工具 **STAR**[4] 将 Clean Reads 比对至参考基因组，输出唯一比对（Uniquely mapped）与多处比对（Multi-mapped）统计；随后通过 **QualiMap (BamQC)**[5] 评估比对结果在基因组窗口上的覆盖深度分布。

6.2 表达定量与下游结果分析方法

仅说明当前启用的结果分析模块，具体过滤阈值与绘图参数详见各图表题注：

1. **基因表达定量与样本关系分析**：上游基于比对结果使用 **RSEM** 构建基因水平表达矩阵，并以 **TPM（Transcripts Per Million）**标准化消除基因长度与测序深度差异。样本间主成分分析（PCA）、表达分布小提琴图及高变异基因（HVGs）聚类热图均预先剔除全样本平均 TPM ≤ 1 的低表达噪声基因，并对表达值执行 $\log_2(\mathrm{TPM}+1)$ 对数转换。
2. **差异表达分析**：读取上游 **DESeq2**[6] 基于负二项分布广义线性模型（GLM）计算的差异检验结果表。报告引擎依据配置文件设定的原始 P 值（`pvalue`）与差异倍数（`log2FoldChange`）阈值对基因进行上下调分类着色并绘制火山图，不修改上游原始检验统计量。
3. **功能富集分析**：读取上游 **clusterProfiler**[7] 针对显著上调与显著下调差异基因集分别执行的 GO（Gene Ontology）与 KEGG 通路超几何分布检验结果。富集气泡图依据输入文件中的基因比例（`GeneRatio`）、富集基因数（`Count`）及多重假设检验校正后 P 值（`p.adjust`）按显著性升序绘制；GO/KEGG 类别严格依据输入字段标识，不主观推断未提供的子分类（如 BP/CC/MF）。

7 溯源信息

本页由 **BioReport** 报告引擎在编译阶段自动捕获并锚定，遵循生物信息学可重复性研究（Reproducible Research）规范，提供从上游原始产出、流程版本到最终交付文档的完整数据血缘（Data Lineage）记录与审计依据。

表 7-1 报告运行与分析溯源信息

项目	内容
项目 ID	PRJ-RNA-PDF-001
生成引擎	BioReport v2.0.0
生成时间	2026-10-17T04:18:03+08:00
报告模块	项目概况、分析流程、质量控制、分析结果、溯源信息、关于
输出布局	single
输出格式	PDF
分析流程版本	RNAFlow example

数据完整性校验（Data Integrity Verification）

下表记录了当前分析任务所引用的核心输入文件及其对应的 **SHA-256 密码学哈希指纹（Cryptographic Hash Fingerprint）**。在科研数据归档、论文补充材料核验或第三方审计时，可随时在终端执行校验命令验证文件的一致性：`sha256sum <filepath>`。若计算输出的哈希值与下表记录完全一致，即可确证上游分析产出在交付与流转过程中未发生任何字节级篡改、损坏或意外修改。

表 7-2 输入文件 SHA-256 指纹

输入文件	数据目录内路径	SHA256
qc_file	index/multiqc_qc_general_stats.txt	b038a6e96f5092fd652b1c79071d134c28063e710a054ce980cd86ec6f817e77
mapping_file	index/multiqc_mapping_general_stats.txt	fc8c900c825d2bfc84c107042bb2852ce2de735f101a625a214b8829717d35b6
tpm_file	index/merge_rsem_tpm.tsv	ed2567825ab0a1298d7f60e857a5f802a54d2ba0b1bc2e7575c025017835d4a7
gene_annotation_file	gene_annotation.tsv	627e6bcb2e34c4d36d00997f543581bad25d2ad2ab73e716c0a1f4050dbda6e0
sample_file	index/sample.csv	6e8e954b2d185c4ec51d6fe42fa6f505e68038befc6f02ab7db499ba2a183936
software_versions_file	software_versions.yaml	53efc18ed502027ec59b4cd9f6577825adc28ef7142d67774149584d7ff8679d
contrasts_file	index/contrasts.csv	532293723bd9fb15cae836714903e4e8b954c1e128c0737ea4e1c3403163b834
fastp_stats_file	fastp_trim_report/multiqc_general_stats.txt	e3fcd6b7aaf5ffb5d09abf77e2e8557063699cb18f8fe4aa8739b90309df2381

指纹用于核验文件完整性。完整 Input Manifest 覆盖 71 个唯一文件（包括声明的结果目录）；完整路径、角色、SHA256 和大小保存在 input-manifest.json。Report / Artifact / Reproduction Manifest 随正常 CLI 输出交付。

8 交付文件与报告说明

BioReport 是 CygnusX BioOps 的配置驱动组学报告生成工具。

本报告由输入数据和配置自动生成，PDF 提供静态图表与结果摘要；完整结果以原始分析文件为准。

8.1 报告生成架构

BioReport 采用配置驱动的模块化报告架构：系统读取已有分析结果，根据 JSON / YAML 配置选择报告章节、绑定输入文件与展示参数，组合 Quarto 文档后生成交互式 HTML 或适合打印归档的 PDF；AI 解读为可选分支，在渲染前生成辅助解释内容。

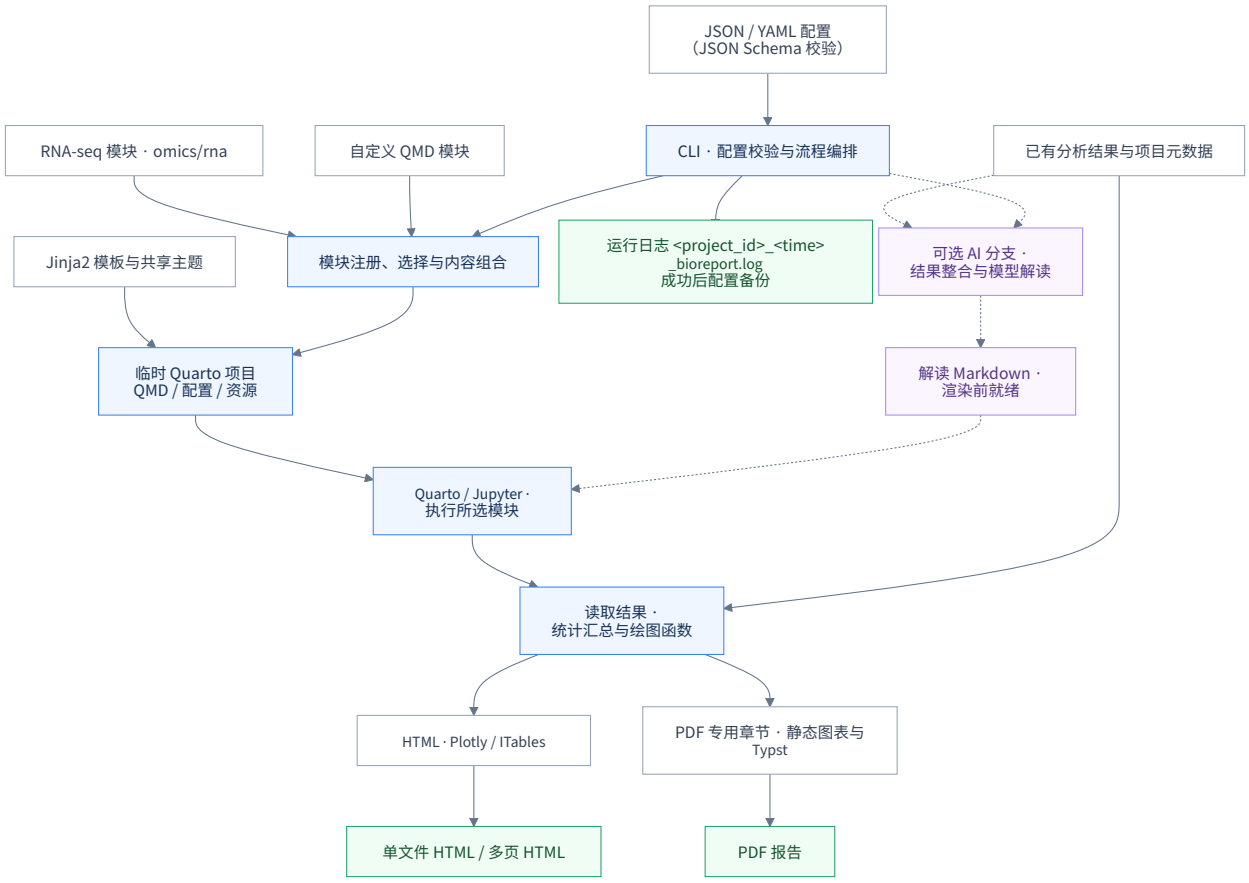


图8-1　BioReport 技术架构：配置、模块组合、分析结果与 HTML/PDF 交付链路。图源与 README 使用同一份 architecture.mmd。

8.2 交付数据目录索引与映射说明

由于 PDF 报告版面仅展示核心统计图表与高显著性记录预览（Top N），完整全量分析结果（如全基因组全部转录本表达矩阵、全部差异检验记录及完整富集通路表）均保存在随报告一同交付的数据目录中。下表列出了报告各模块数据源对应的配置键名（输入类型）及其在交付数据包内的相对路径映射，研究人员可按路径使用 Excel、R 或 Python 直接读取原始文本文件进行深度挖掘：

表 8-1 报告输入文件与数据路径

输入类型	数据目录内路径
qc_file	index/multiqc_qc_general_stats.txt
mapping_file	index/multiqc_mapping_general_stats.txt
tpm_file	index/merge_rsem_tpm.tsv
gene_annotation_file	gene_annotation.tsv
sample_file	index/sample.csv
software_versions_file	software_versions.yaml
contrasts_file	index/contrasts.csv
fastp_stats_file	fastp_trim_report/multiqc_general_stats.txt
fastp_report_dir	fastp_trim_report/multiqc_short_read_trim_report_data
fastq_screen_r1_dir	fastq_screen_report/fastq_screen_multiqc_r1/multiqc_r1_fastq_screen_report_data
fastq_screen_r2_dir	fastq_screen_report/fastq_screen_multiqc_r2/multiqc_r2_fastq_screen_report_data
qualimap_dir	QualiMap/multiqc_data
deg_dir	res/DEG
enrichment_dir	res/Enrichments

报告生成器：BioReport v2.0.0。配置来源：report.rna.pdf.json。数据目录（交付目录，配置值 ../examples/rna-seq/data）内的文件按相对路径描述；配置备份随正常 CLI 输出保存。

8.3 开发者与项目信息

BioReport 是 CygnusX BioOps 体系下的模块化多组学报告生成组件。工具基于 Python 与 Quarto 构建，以 JSON / YAML 统一配置驱动报告生成，无缝集成 Plotly 交互式图表与 Itables 动态表格，并支持 HTML 与 PDF 双格式输出，致力于将复杂的生信分析结果组织为结构清晰、证据可追溯、可复用分享的标准化科研交付物。



图8-2　BioReport 愿景：从分析结果到可验证、可追溯的科研报告。

参考文献

[1] EWELS P, MAGNUSSON M, LUNDIN S, 等. MultiQC: summarize analysis results for multiple tools and samples in a single report[J/OL]. Bioinformatics, 2016, 32(19): 3047-3048. DOI:10.1093/bioinformatics/btw354.

[2] CHEN S, ZHOU Y, CHEN Y, 等. fastp: an ultra-fast all-in-one FASTQ preprocessor[J]. Bioinformatics, 2018, 34(17): i884-i890.

[3] WINGETT S W, ANDREWS S. FastQ Screen: A tool for multi-genome mapping and quality control[J/OL]. F1000Research, 2018, 7: 1338. DOI:10.12688/f1000research.15931.2.

[4] DOBIN A, DAVIS C A, SCHLESINGER F, 等. STAR: ultrafast universal RNA-seq aligner[J]. Bioinformatics, 2013, 29(1): 15-21.

[5] OKONECHNIKOV K, CONESA A, GARCÍA-ALCALDE F. Qualimap 2: advanced multi-sample quality control for high-throughput sequencing data[J]. Bioinformatics, 2016, 32(2): 292-294.

[6] LOVE M I, HUBER W, ANDERS S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2[J]. Genome Biology, 2014, 15(12): 550.

[7] YU G, WANG L G, HAN Y, 等. clusterProfiler: an R package for comparing biological themes among gene clusters[J]. Omics: A Journal of Integrative Biology, 2012, 16(5): 284-287.